

Villa Treny: una sociedad con presupuesto cero

Investigación para Alejandro Treny. 8 de septiembre de 2026.

La decisión

Hay margen para dar a los 25 habitantes mucha más capacidad de decisión que las cuatro oportunidades globales al día del diseño anterior. La nueva implementación separa el reloj físico del pensamiento, conserva proyectos entre llamadas y permite conversaciones con una respuesta propia por participante. Workers AI y el proyecto Free de Groq ya provisionado son la base cloud; el modelo local instalado se ha evaluado como posible complemento, sin conectarlo al mundo publicado.

No hace falta eliminar las operaciones básicas del motor. Deben convertirse en herramientas para ejecutar propósitos más amplios: buscar ayuda, negociar condiciones, cumplir un compromiso o cambiar de estrategia. La generación de texto nunca puede crear recursos, atribuir consentimiento a otra persona ni demostrar por sí misma que una meta se ha cumplido.

La revisión reúne documentación oficial vigente, doce líneas principales de investigación, alternativas contrastadas y pruebas reales aisladas. Las ejecuciones locales completas producen conversaciones entre voces independientes y consecuencias físicas, pero todavía no acuerdos económicos negociados. La primera versión ya se ha desplegado conservando el mundo y los 25 habitantes han completado al menos una decisión. La continuidad y calidad a largo plazo siguen en observación. Las recomendaciones son inferencias de ingeniería; los resultados de otros experimentos no garantizan una sociedad interesante ni una cuota disponible para cualquier cuenta.

Capacidad gratuita que podemos contabilizar

Cloudflare publica 10.000 neuronas diarias compartidas por la cuenta, con reinicio a las 00:00 UTC. En Workers Free, al agotarlas fallan las operaciones. Workers Paid permite sobrecostes y algunos modelos requieren pago: quedan fuera de la propuesta. [Cloudflare: precios, actualizado 28-8-2026](#).

La siguiente comparación es un cálculo, no una medición: 2.000 tokens de entrada y 512 generados por petición, sin caché, fallos ni otros consumidores. Los tokens generados incluyen razonamiento cuando existe.

Modelo en Workers AI	Neuronas por petición	Techo aritmético con 10.000/día
Granite 4.0 H Micro	8,285	1.207
Qwen 3 30B A3B FP8	24,853	402
GLM 4.7 Flash	29,637	337
Gemma 4 26B A4B	32,146	311
GPT-OSS 120B	98,545	101

Fórmula: neuronas = (entrada × tarifa de entrada + salida × tarifa de salida) / 1.000.000. Las tarifas son las publicadas por Cloudflare. Los modelos baratos pueden necesitar más correcciones o producir peores decisiones; ese coste debe medirse antes de elegirlos. GPT-OSS 120B permite comparar menos decisiones con más capacidad de razonamiento, sin presuponer que vaya a ganar. [Catálogo Granite](#), [catálogo Qwen](#), [GPT-OSS 120B](#).

Groq publica para GPT-OSS 20B/120B: 30 RPM, 1.000 RPD, 8.000 TPM y 200.000 TPD en su tabla Free. No son cuotas multiplicables por clave. El proyecto existente habitat-prod fue provisionado con límites inferiores: 10 RPM, 200 RPD, 6.000 TPM y 150.000 TPD, y únicamente OSS 20B. Con 2.000+512 tokens, ese tope diario de proyecto equivale a 59 peticiones completas sin caché. Se conserva hasta verificar y cambiar la configuración de cuenta. [Groq: límites](#), [ámbito de proyectos](#).

La caché de prefijos de Groq puede descontar tokens de los límites después de procesarlos, pero no asegura aciertos. No se presupone descuento de caché para Qwen en Cloudflare. Tampoco se presenta batch como una segunda cuota gratuita. [Caché Groq](#), [caché Workers AI](#).

Alternativas: qué aporta cada una

Mistral es el candidato adicional más relevante. Su plan Free anuncia 10 USD mensuales de crédito API, compartido con Studio y Vibe. Con PAYG apagado puede detenerse hasta la renovación. La documentación de automatización contempla claves de consola Free. Sin embargo, los términos europeos separan API/Studio del contrato consumidor y los términos comerciales adicionales piden información de facturación y un método de pago válido. La disponibilidad concreta, los límites por minuto y las condiciones de esta cuenta siguen pendientes; no se suman estos créditos a la capacidad provisionada. [Mistral: plan Free](#), [suscripciones](#), [términos europeos 7-8-2026](#), [términos adicionales 5-8-2026](#).

OpenRouter es un complemento pequeño: 50 peticiones gratuitas al día y 20 RPM para toda la cuenta. El nivel de 1.000 exige una compra previa. Los fallos también consumen peticiones. Su integración necesitaría modelos :free vigentes, precios máximos cero y controles de tratamiento de datos; no basta activar un router general. No hay una cuenta nueva provisionada para Villa. [OpenRouter: precios](#), [guía oficial 12-6-2026](#), [restricción de precio](#).

Inferencia local: este Mac tiene 48 GiB, M5 Pro, oMLX 0.6.4 y unos 19 GiB de pesos Qwen 3.6-35B-A3B de 4 bits completos. Ya se han ejecutado varias pruebas aisladas, incluidas pasadas completas de 37 respuestas. Una medición previa alcanzó unos 20,4 GiB de memoria física y un pico de 21,9 GiB; son observaciones de ese proceso, no una garantía de capacidad o velocidad bajo otras cargas. Podría ser un trabajador opcional mientras esté despierto; actualmente no existe un puente de inferencia local hacia producción. Los servidores de prueba se limitan a 127.0.0.1:8018 y se detienen al terminar cada lote. No hay tarifa API local, pero sí consumo de hardware y tiempo. [oMLX 0.6.4](#), [modelo MLX](#), [revisión local V7](#) (artefacto del repositorio).

Otras ofertas no forman una base recurrente equivalente: Cerebras anuncia actualmente 5 USD iniciales, Fireworks 1 USD inicial y Together exige compra mínima. Las antiguas listas gratuitas pueden estar desactualizadas. [Cerebras](#), [Fireworks](#), [Together](#).

Hugging Face ofrece 0,10 USD mensuales al usuario gratuito. Cohere reserva sus claves de prueba a evaluación; NVIDIA limita su API de prueba a usos no productivos. GitHub Models se retiró el 30-7-2026. Gemini tiene modelos gratuitos, pero sus términos exigen Paid Services para clientes API disponibles en el EEE; no es una base confirmada sin facturación para esta web española. [Hugging Face](#), [Cohere](#), [NVIDIA](#), [retirada GitHub](#), [términos Gemini](#).

Qué demuestra la investigación de sociedades

1. Memoria y proyectos: Generative Agents. Park y colaboradores, UIST 2023, estudian 25 personajes durante dos días. Recuperan recuerdos, forman reflexiones apoyadas en ellos y descomponen planes próximos. Las ablaciones favorecen el sistema completo, pero también documentan recuerdos inventados, recuperación fallida e intenciones que no llegan al plan. Adoptamos continuidad y reflexión selectiva; dos días no prueban meses de autonomía. [Artículo y ablaciones](#).

2. Hechos y percepciones: AgentSociety. Piao y colaboradores, 2025/revisión 2026, separan estado, acontecimientos objetivos y percepciones del agente, con necesidad, planificación y conducta. Su marco paralelo alcanza gran escala con 24 GPU; eso acredita rendimiento distribuido, no ahorro equivalente de tokens ni riqueza de cada personaje. Adoptamos la separación de entorno, mensajes y estado individual. [Arquitectura revisada](#), [marco ACL Industry 2025](#).

3. Deseo frente a resultado: Concordia. Vezhnevets y colaboradores, 2023, dejan que el agente proponga una acción y que el entorno resuelva consecuencias y conflictos. Las variables concretas pueden tener reglas numéricas. Nuestra adaptación usa código para saldos, recursos y permisos: querer comprar no significa haber comprado. El trabajo es una arquitectura con ejemplos, no una garantía comparativa de coste. [Artículo](#).

4. Intereses privados y evaluación: SOTOPIA. Zhou y colaboradores, ICLR 2024, distinguen objetivos, relaciones, secretos, normas y beneficio material en escenarios sociales. SOTOPIA-PI añade entrenamiento; la evaluación humana revela que un juez automático puede sobrevalorar el modelo entrenado. Retenemos objetivos privados y varias dimensiones. Las revisiones de esta entrega son del asistente; queda pendiente una muestra evaluada por personas. [SOTOPIA](#), [SOTOPIA-PI](#), [ACL 2024](#).

5. El riesgo del guionista omnisciente. Zhou y colaboradores, EMNLP 2024, comparan un guionista con acceso a ambos personajes frente a voces independientes. En una negociación, el primero alcanza 94% de acuerdos y las segundas 30%. Un relato más fluido puede esconder información privilegiada y complacencia. Villa debe producir cada voz desde su propio contexto; reducir llamadas escribiendo ambas partes cambiaría el fenómeno que queremos observar. [Comparación y límites](#).

6. Cooperación con escasez: GovSim. Piatti y colaboradores, NeurIPS 2024, estudian cinco agentes y recursos regenerables. Retirar comunicación aumenta 22% la sobreexplotación, pero la diferencia agregada de supervivencia no es significativa. Adoptamos recursos finitos y contrastar promesas con consumo real. No inferimos que añadir conversación garantice sostenibilidad. [Cooperate or Collapse](#), [métodos y apéndiceD](#).

7. Proyectos y trueque: Port of Mars. Slumbers, Leibo y Janssen, 2025, combinan infraestructura común, cinco colonos y objetivos propios. Conservar planes mejora la continuidad frente al historial indiscriminado. Las ofertas y aceptaciones se separan, pero la reunión completa se escribe en una llamada. Adoptamos proyectos y negociación concreta; evitamos ese narrador colectivo. [Método y apéndiceB](#).

8. Memoria económica: EconAgent. Li y colaboradores, ACL 2024, simulan decisiones de trabajo y consumo de 100 agentes durante 240 meses, con percepción y reflexión. Sus ablaciones muestran diferencias macroeconómicas. Adoptamos que ingresos, ahorro y deuda influyan en planes futuros; reproducir correlaciones agregadas no demuestra una personalidad ni una conversación convincente. [Artículo final](#).

9. Instituciones: AgentElect. Faulkner y colaboradores, 2026, comparan líderes elegidos, fijos y ausencia de liderazgo en 640 simulaciones. Las mejoras agregadas no son universales. Los investigadores introducen elecciones y reglas: el experimento no demuestra que nazcan solas. Para Villa, cualquier norma colectiva debe conservar propuesta, aceptación y resultado observables. [Métodos y limitaciones](#).

10. Activación selectiva: OASIS. Yang y colaboradores, revisión 2025, separan entorno, agentes e inferencia en redes sociales. La gran población se activa parcialmente y utiliza infraestructura importante. Adoptamos eventos y cola asíncrona; no equiparamos millones de perfiles ocasionales con millones de vidas continuas. [Versión 5](#).

11. Eficiencia y su denominador: GASim. Zhou y colaboradores, ACL 2026, reportan 9,94 veces de aceleración y menos del 20% de tokens de referencia mediante recuperación y simulación híbrida. Muchos individuos pasan a actualizaciones numéricas; las métricas son curvas de opinión. Adoptamos recuperación barata, pero conservamos los 25 residentes como individuos. [Publicación ACL](#).

12. Qué significa emergencia. Ashery, Aiello y Baronchelli, Science Advances 2025, estudian convenciones en juegos por parejas de 24 agentes. La crítica posterior señala posible reconocimiento de patrones aprendidos; la respuesta distingue conocer el juego de predecir la convención concreta. Para probar emergencia habría que variar etiquetas, incentivos y redes. Esa comparación aún no se ha realizado en Villa; una única historia verosímil no identifica su mecanismo. [Estudio](#), [crítica](#), [respuesta](#).

Cómo se aplica a Villa

Cada persona dispone de estado mental propio, capacidad de conservar un proyecto con pasos ejecutables, recuerdos con referencias y un historial de resultados. La cola reparte revisiones personales y respuestas a mensajes, y considera observaciones recientes del motor. La primera V7 conservó 22 proyectos; las pasadas posteriores llegaron a 25, muchos sin pasos físicos. Tener un propósito escrito no demuestra que sea útil o realizable. El reparto debe reservar oportunidades también para quienes no están en el centro de la trama.

Cada turno de conversación pertenece a una persona. El receptor puede aceptar, rechazar o cambiar las condiciones. El acuerdo solo nace con aceptación del contenido exacto; el motor verifica saldo, trabajo, plazo y cumplimiento. Si la cuota termina, la conversación queda pendiente hasta su caducidad. No inventamos una respuesta para cerrar una escena.

El reloj físico conserva su propio ritmo. Las acciones de un plan sustituyen decisiones rutinarias dentro del presupuesto de trabajo existente. Pensar más no produce más alimentos gratuitamente. Los recuerdos distinguen lo sucedido, lo comunicado por otra persona y la interpretación propia; las reflexiones no se guardan como hechos comprobados.

La cola necesita identidades por residente y revisión mental. Otro personaje puede haber pensado entre petición y respuesta sin invalidar automáticamente el trabajo. Aun así, deben revalidarse turno, caducidad, control del mundo y recursos. Un resultado recibido se guarda antes de aplicar sus efectos una sola vez.

El visor incorpora proyectos, intervenciones, términos y cumplimiento, además del diario, relaciones y economía, y distingue salud del reloj y salud cognitiva. Los proyectos privados no muestran su propósito al observador. Las relaciones pueden actualizarse tras una valoración sin avanzar la guardia: el cliente utiliza la revisión del mundo, no solo el reloj. Que los muñecos caminen o que el servidor responda no demuestra que el modelo esté decidiendo.

Qué hemos comprobado en Villa

La inspección inicial encontró cuatro restricciones evitables: una sola oportunidad global por guardia; un contrato JSON más permisivo que su decoder; un bloqueo de 24 horas por una respuesta inválida; y reservas máximas que no liberaban la parte no consumida cuando el proveedor sí informaba el uso completo. La recuperación también asumía pocas filas mutables, incompatible con centenares de trabajos diarios.

En la revisión 29, ambos proveedores estaban bloqueados por respuestas rechazadas, con solo 9 neuronas y 1.810 tokens medidos ese día. Las respuestas antiguas descartadas no permiten reconstruir su causa exacta. No corresponde atribuirles sin más a alucinaciones. La implementación nueva distingue problemas de formato, validación, disponibilidad y cuota; guarda la respuesta antes de aplicarla y conserva toda la reserva cuando el consumo es incierto.

Los experimentos siguientes usan mundos ficticios aislados. No alteraron la simulación publicada. Cada prueba conserva sus entradas, salidas, errores, consumo y hashes de las fuentes; las pruebas fallidas no se sobrescriben al cambiar el código. «Decisión aceptada» significa que pasó las reglas, no que fuera interesante o acertada.

Prueba	Llamadas y neuronas	Resultado observado
V1: Qwen, Granite y GLM	12 / 122	Errores de cantidades e identificadores; GLM agotó el límite de 512 tokens de salida.
V2: opciones calculadas por el motor	8 / 63	8 respuestas legales en casos simplificados; persistían fallos semánticos.
V3: integración con el núcleo real	25 intentos / 321	24 respuestas completas, ninguna aceptada; un error OAuth retuvo una reserva de 55.
Diagnóstico de formato	6 / 52	Ninguna decisión aceptada; añadir JSON mode por sí solo no bastó.
Protocolo contextual: prueba corta	2 / 18	Ambas aceptadas; una respondió a un mensaje inexistente.
V4: 25 habitantes, réplicas y una guardia	37 / 250	29 aceptadas, 12 conversaciones y ningún acuerdo aceptado.
Alternativas con el mismo contexto	4 / 100	Dos Gemma aceptadas con detalles inventados; GLM falló una fecha; otro OAuth retuvo 68.
Instrucciones y razonamiento	4 / 157	GLM agotó 1.536 tokens en ambos casos; Gemma mantuvo errores de tarea o partes.
V5: contrato de elección	4 / 58	Cuatro proyectos válidos, ningún mensaje; detenida en la primera revisión.

Prueba	Llamadas y neuronas	Resultado observado
V6: primer contacto y respuesta obligatorios	7 intentos / 242	Seis mensajes válidos con problemas semánticos; un OAuth retuvo 144.
GPT-OSS 120B, mismo contexto V6	2 / 116	Ambas aceptadas; seguían una confusión de identidad y acciones sin relación causal con el objetivo.
GPT-OSS 120B, identidad explícita	2 / 111	Nombres correctos y propósitos sociales sin trabajo ficticio; persiste un detalle no aportado.
Qwen local, contexto original e identidad	4 / o cloud	Cuatro respuestas válidas, pero trabajo o inspección siguen representando tareas que no realizan.
V7 local: capacidades, 25 habitantes, réplicas y una guardia	37 / o cloud	29 decisiones aceptadas; nueve conversaciones con ambas voces; seis pasos de planes ejecutados; ningún acuerdo negociado.
GPT-OSS 120B, dos casos exactos de V7	2 / 160	Ambas aceptadas: B responde sin el contrato agrícola ajeno al tema y L propone una reparación pendiente. Persisten defectos semánticos.
Qwen local, parámetro de pensamiento activado sobre esos dos casos	2 / o cloud	Ambas aceptadas, sin evidencia de una fase de razonamiento generada; gramática JSON sin fase de pensamiento configurada.
GPT-OSS 120B, compatibilidad de condición de acuerdo	1 / 82	El proveedor acepta el esquema, pero la respuesta agota los 512 tokens de esta prueba y no se aplica.
Qwen local, condición de acuerdo completa	37 / o cloud	37 aceptadas, 12 conversaciones bilaterales y seis pasos físicos de planes; ningún acuerdo.
Qwen local, propuestas desde el primer contacto	37 / o cloud	37 aceptadas y siete pasos físicos de planes; tampoco emite ofertas ni acuerdos.
Qwen local, tres parejas con distinto orden de campos	6 / o cloud	Las seis pasan, pero cada pareja devuelve el mismo contenido; ninguna oferta. Cambiar el orden no resuelve el problema observado.
Qwen local, mensaje abierto y ofertas	6 / o cloud	Cinco propuestas explícitas; ninguna aceptación. El lote conservaba una descripción contradictoria del campo de cierre, documentada después.

Prueba	Llamadas y neuronas	Resultado observado
Qwen local, aceptación exacta aclarada	1 / 0 cloud	Lior cambia el plazo y hace una contrapropuesta; no acepta la anterior.
Qwen local, tres réplicas finales	3 / 0 cloud	Juno escribe que acepta, pero emite otra propuesta. Cero acuerdos y pagos; el motor mantiene esa diferencia.

El total conservador de las pruebas cloud realizadas hasta este corte es **1.852 neuronas**, incluidas **267 reservadas por consumo desconocido**: 55, 68 y 144 de los tres intentos OAuth ambiguos. Quedan 148 de las 2.000 apartadas para investigación. No se presentan esas reservas como consumo medido ni se liberan suponiendo que el proveedor no trabajó. El total incorpora redondeo al alza por llamada y no sustituye un extracto de facturación. V5 y V6 son prefijos detenidos; las tres pasadas locales completas sí ejecutan sus 37 llamadas cada una. Las comparaciones de dos contextos son demasiado pequeñas para establecer fiabilidad o clasificar modelos.

V4 demuestra que el límite técnico funciona: los pagos imposibles y las partes incompatibles no se aplican. También revela que la calidad todavía importa mucho: algunas respuestas copian el perfil o una frase anterior, confunden al destinatario, inventan circunstancias o eligen acciones que no avanzan su objetivo. Veinte personajes acabaron sin proyecto persistente. Este resultado no acredita una sociedad autónoma satisfactoria.

Continuar ocho guardias sin llamadas nuevas produjo 200 acciones reales. Se completó un paso pendiente y otro fue rechazado; no surgió un acuerdo. Las identidades, los proyectos y las marcas de pensamiento se conservaron, con un residuo monetario máximo de $1,14 \times 10^{-13}$. Es continuidad física, no adaptación cognitiva. Tres pruebas separadas de 365 días y cero modelos también conservaron el mundo y sus límites; no demuestran interés narrativo.

La revisión detectó además un fallo de precisión monetaria: después de dos transferencias de 0,10, un saldo suficiente podía representarse como 16,799999999999997 y rechazar 16,80. En otro caso dejaba trabajo realizado sin pagar. La corrección usa una tolerancia mínima compartida, conserva los salarios fraccionarios y sigue rechazando una falta real de 0,01.

V7 local mejora la continuidad, pero muestra problemas concretos. De las 37 decisiones, se aceptan 22 de las 25 primeras oportunidades, tres de las ocho réplicas y las cuatro revisiones posteriores. Persisten 26 mensajes en 12 conversaciones; nueve tienen ambas voces. Hay 22 proyectos, de los que 16 no contienen pasos físicos. Los ocho intentos de proponer trabajo se rechazan: faltaba el campo requerido para mantener abierta la conversación, y varios además proponían tareas ajenas a lo hablado. El resultado es **cero ofertas persistidas, cero acuerdos, cero aceptaciones y cero pagos negociados**. Añadir automáticamente el campo ausente habría permitido persistir algunas propuestas incoherentes; todavía habría hecho falta la aceptación independiente del interlocutor para crear una obligación. *Lectura completa de las 37 respuestas* (artefacto del repositorio).

En la única guardia de V7 ocurren 25 acciones correctas según el motor: seis proceden de planes del modelo y 19 de la política rutinaria. Los planes producen excavación, reparación, cultivo y filtrado; los otros dos pasos son ir a una sala donde el personaje ya está. La contabilidad queda en 315 células iniciales menos dos consumidas por reparación: 313 en poder de los habitantes, sin fuga ni pago negociado. Se aplican seis valoraciones, cada una con un punto de confianza hacia el interlocutor; dos valoraciones incluidas en decisiones rechazadas no producen efectos. Algunas interpretan una promesa como algo ya cumplido. Una referencia válida protege contra identificadores inventados, pero no garantiza una lectura correcta del mensaje.

GPT-OSS 120B se probó con dos estados anteriores a la respuesta exactamente iguales a V7: la primera réplica de B y la primera intervención de L. Ambas decisiones pasan, con **83 y 77 neuronas contabilizadas**, respectivamente, y latencias observadas de 11,786 y 10,554 segundos. B elimina el contrato agrícola ajeno a la conversación y ofrece contenido propuesto para revisar, pero añade una acción de beber que no ayuda al propósito y termina una pregunta a mitad del límite de caracteres. L crea una reparación pertinente; su expectativa de recibir un favor no se convierte en deuda ni consentimiento de Juno. No hay ejecución física ni acuerdo nuevo en estos dos casos. *Comparación OSS con V7* (artefacto del repositorio).

Una comparación local usa los mismos mensajes, esquema y semilla, cambiando solo `enable_thinking:true` y el máximo de salida de 1.024 a 4.096 tokens. Devuelve dos decisiones aceptadas, de 138 y 131 tokens, en 2,943 y 2,500 segundos. **No demuestra razonamiento más largo**: las respuestas no incluyen contenido de razonamiento y el servidor no aporta un contador separado. La configuración aislada carece de un analizador de razonamiento; el código instalado compila una gramática JSON sin fase de pensamiento. El parámetro cambia el prefijo de generación, pero por sí solo no habilita esa fase. B promete consultar y redactar protocolos sin crear herramientas o pasos para hacerlo; L sí propone ir a Workshops y reparar, todavía pendiente. Ninguna salida se acerca siquiera al máximo anterior de 1.024. No atribuimos la mejora a deliberación ni equiparamos ese techo local de 4.096 al presupuesto cloud. *Revisión del parámetro local* (artefacto del repositorio).

El punto de control de la primera versión publicada pasa **840 pruebas de aplicación, 181 de Worker, 11 comprobaciones Node y 18 recorridos de navegador**, además de compilación, ensayo de despliegue y seis pruebas locales de alojamiento sin conexiones externas. Incluye la distinción entre pasos terminados y propósito cumplido, y la identificación de acciones heredadas sin inventar su destino. Las pruebas cubren voces privadas, consentimiento, referencias falsas, duplicados, pausa, caducidad, fallos de proveedor, límites móviles y recuperación paginada. Los resultados técnicos no puntúan por sí mismos la calidad de una conversación.

La publicación se realizó hacia las 13:09 UTC del 8 de septiembre. La guardia física anterior avanzó por su reloj normal a las 13:08, antes del cambio. Las copias completas inmediatamente anterior y posterior conservan exactamente los mismos bytes del mundo en el día 107, guardia III, los campos anteriores del reloj y control, y todas las columnas anteriores de once tablas de historia y cuotas. La reconciliación posterior instaló el pensamiento sin reiniciar el reloj. La primera petición real de Ama consumió 1.712 tokens de entrada y 344 de salida, contabilizados como 78 neuronas; inició una conversación y conservó un proyecto. No demuestra por sí sola autonomía sostenida. *Prueba de continuidad* (artefacto del repositorio).

La auditoría posterior del mundo real reconstruyó las entradas de las primeras once decisiones: coinciden los 33 hashes de sistema, contexto y preparación, las once listas de referencias y la proyección pública final. Detectó un ejemplo concreto de propagación: Kes afirmó que había documentos pendientes sin recibir ese dato; Bex después pidió esos documentos. Edda conocía correctamente las 21 unidades de material, pero inventó una asignación anterior de cuatro. Ulla afirmó disponer de papel y tinta sin inventario aportado. Son fallos del contenido; sus frases no modificaron existencias ni crearon acuerdos. La revisión es del asistente, no una evaluación humana. *Revisión de las once decisiones* (artefacto del repositorio), *prueba reproducible* (artefacto del repositorio).

La captura completa de las 13:43 UTC contiene nueve personas con pensamiento y once decisiones aplicadas por 774 neuronas confirmadas. Hay seis conversaciones, tres con ambas voces, nueve proyectos y tres pasos pendientes; ninguna guardia física nueva ni acuerdo. Un ensayo sobre una copia ejecuta esos tres pasos y 22 rutinas conservando el dinero, pero es una previsión sin nuevas decisiones del modelo. A las 14:25, el estado público ya muestra 19 de 25 personas y 25 peticiones correctas del modelo, por 1.899 neuronas confirmadas. Estos son dos cortes diferentes de observación. *Análisis de la recuperación* (artefacto del repositorio), *estado público posterior* (artefacto del repositorio).

La observación pública de las 14:57 UTC ya muestra cobertura de los 25 habitantes. Registra también una respuesta correcta de Groq de 2.425 tokens de entrada y 129 de salida, tras una respuesta truncada de Cloudflare. La copia completa posterior, de las 14:59, conserva la revisión 102 y la misma guardia física. Esto acredita cobertura inicial y un respaldo real; no convierte las frases en hechos ni demuestra autonomía económica sostenida. *Estado con los 25 habitantes* (artefacto del repositorio).

Las pruebas locales suman 133 llamadas con los mismos archivos de pesos disponibles. Las tres pasadas completas, de 37 llamadas cada una, mantienen cero acuerdos. La comparación de seis peticiones sobre el orden conserva las entradas y sólo reordena campos: sus tres parejas producen contenido idéntico. Por tanto, no respalda esa modificación como solución ni permite concluir que los habitantes no quieran negociar. *Comparación de orden* (artefacto del repositorio), *pasada con condición de acuerdo* (artefacto del repositorio), *pasada de propuestas iniciales* (artefacto del repositorio).

La gramática tenía una dificultad concreta: tras generar un mensaje sin el campo de cierre, ya no permitía añadir una propuesta válida. El protocolo 4 admite omitir ese campo, respetando la conversación abierta que ya interpreta el motor. Sigue rechazando un acuerdo acompañado de cierre explícito y mantiene las versiones históricas. Se contrastó con el compilador real sin llamar a modelos. Corregir esta rama hizo posibles nuevas propuestas, pero no resolvió toda la negociación. *Auditoría de gramática y alternativas* (artefacto del repositorio).

En seis pruebas posteriores se emitieron cinco propuestas. Había además una descripción contradictoria que todavía pedía el campo omitido; ese lote no es un experimento limpio de una sola variable. Tras corregirla y aclarar los papeles de trabajador y pagador, una respuesta de Lior cambió el plazo de 403 a 401: era una contrapropuesta válida. En las tres réplicas siguientes se repitieron condiciones, pero Juno escribió «acepto» mientras elegía otra propuesta estructurada. El motor no interpretó esa frase como consentimiento. Los acuerdos y pagos siguieron en cero. Dos reparaciones en la copia se debieron a planes personales, no al cumplimiento de un contrato. *Seis propuestas y réplicas* (artefacto del repositorio), *aclaración de aceptación* (artefacto del repositorio), *tres réplicas finales* (artefacto del repositorio).

Una revisión adicional sin inferencia comprobó las tres ofertas entrantes del último lote. Sus identificadores y términos estaban presentes, y aceptar cada identificador pasaba el esquema, el compilador de gramática y el motor en copias aisladas. La aceptación era técnicamente accesible. Esas aceptaciones contrafactuales no son decisiones del modelo ni acuerdos ocurridos en la simulación. *Auditoría de la ruta de aceptación* (artefacto del repositorio).

La publicación de SQL8 conserva exactamente el mundo, el estado social, todas las filas anteriores de 20 tablas y todos los campos de control entre las copias de las 15:37:17 y 15:38:36 UTC. Solo se añade la marca de migración. La revisión permanece en 128 y la siguiente guardia en las 19:08:04 UTC. *Continuidad de SQL8* (artefacto del repositorio).

La primera respuesta real del protocolo 4 procede de Quim, mediante Groq: 4.523 tokens de entrada y 166 de salida, 1,854 segundos y consumo completo confirmado. De los 5.559 tokens reservados se liberan 870. Crea una oferta de 2 células para Gita; no hay aceptación ni movimiento de dinero. No consta intento ni reserva de Cloudflare para ese trabajo. El salto por espera de cuota se infiere del flujo de código y los registros completos; no existe una hora de admisión de Cloudflare guardada que permita afirmar más. La frase «aquí tienes 2 células» adelanta un hecho que todavía no ha ocurrido. *Recibo, oferta y saldos* (artefacto del repositorio).

Límites operativos y siguiente decisión

El intervalo mínimo es de tres minutos: como máximo 480 oportunidades diarias, repartidas entre revisiones y réplicas; las guardias físicas siguen durando seis horas. La cadencia fija de la primera publicación podía agotar la cuota durante las primeras horas. La nueva política, publicada junto con SQL8 y el protocolo 4 hacia las 15:38 UTC, distribuye cada proveedor hasta su renovación según el saldo, el coste reciente y la reserva máxima necesaria. Prioriza la primera oportunidad de cada persona y permite usar Groq mientras Cloudflare espera. Un contexto grande no debe bloquear a los demás: la búsqueda comprueba hasta 25 candidatos usando una única lectura de ventana por proveedor. El límite propio de Workers AI sigue en 8.000 neuronas, dejando 2.000 fuera del motor; Groq conserva los topes provisionados.

El ensayo de agenda usa costes supuestos explícitos y conversaciones sintéticas, sin modelos ni cambios de producción. La política anterior se queda sin admisiones a las 6 h 12 min o 7 h 9 min, según el consumo confirmado de Groq. La nueva reparte 122 o 140 llamadas durante el día y alcanza 24 o 25 personas revisadas recientemente al corte de las 14 horas. No es una predicción de calidad ni garantiza una respuesta por persona cada seis horas: cambia con el tamaño de los contextos, fallos y consumo real. *Regla y reproducción de la cadencia* (artefacto del repositorio).

Gemma fue el modelo seleccionado durante parte de la preparación. **GPT-OSS 120B es ahora el principal publicado**, por la mejora concreta observada en los dos casos V7. La reserva sigue siendo conservadora: en los 37 contextos históricos V7 era de 371 a 582 neuronas por petición completa; no es el coste del contrato final. Si se repitieran los consumos de 77-83 de las dos muestras cloud, con liquidaciones completas, cabrían aproximadamente 90-100 respuestas diarias dejando margen para admitir la siguiente reserva. Si el uso no se confirma, solo cabrían 13-21 reservas. No son garantías de calidad, duración ni rendimiento diario.

Los 37 contextos históricos V7 cabían individualmente en el límite de 6.000 tokens de Groq: reservan entre 3.266 y 4.944, incluida toda la salida permitida. Suman 155.530 tokens, por lo que no cabrían todos el mismo día sin liberar consumo confirmado. El margen diario de 150.000 permitía 30-45 intentos con esas reservas. El respaldo real posterior ya está medido en los recibos publicados, con contratos diferentes. Los 25 habitantes revisados cada seis horas requieren unas 100 revisiones diarias antes de contar réplicas y errores; una réplica también puede cubrir la revisión de su autor. El reparto garantiza oportunidades según la cola y las cuotas disponibles, no una respuesta cada seis horas a cualquier coste. *Decisión de proveedor y cálculo reproducible* (artefacto del repositorio).

Con el contrato final y un caso sintético legal de 24 préstamos, el contador reserva 7.029 tokens para Ama y 5.480 para Dima; los máximos conservadores de Cloudflare son 808 y 640 neuronas. Ama supera el límite de minuto de Groq, aunque Dima sí cabe. La búsqueda ahora prueba otros residentes sin gastarles el turno ni recortar compromisos, por lo que ese contexto grande no detiene a toda la sociedad. Estas son reservas medidas sobre entradas sintéticas completas, no consumos observados del proveedor ni un intervalo general para cualquier persona. *Medición final con instrucciones inglesas* (artefacto del repositorio).

El contrato nuevo deriva las partes y fechas de una elección explícita -dar, pedir, prestar, contratar o aceptar- y exige ubicaciones válidas. Requiere un mensaje en el primer contacto disponible y al responder, permitiendo revisiones privadas después. Esto es una regla de agenda, no una demostración de sociabilidad espontánea. Las capacidades se nombran por su efecto: acumular crédito laboral, registrar una visita o filtrar agua. Observar sin ningún efecto deja de ofrecerse para planes nuevos. Los registros y acuerdos antiguos mantienen sus acciones y significado originales. Renombrar reduce ambigüedad; no garantiza que un objetivo escrito libremente corresponda a sus pasos.

Una valoración opcional permite que la persona cambie un punto de su propia confianza, afecto, admiración o resentimiento tras un mensaje recibido real. El destinatario se deriva del interlocutor; no puede decidir los sentimientos ajenos, cambiar dinero ni aceptar acuerdos mediante esa opinión. Cada mensaje se valora como máximo una vez, con un motivo privado marcado como interpretación. Tener una referencia válida no demuestra que la interpretación sea acertada.

El cálculo de Groq cuenta el mensaje de sistema, el contexto y el esquema completos mediante tiktoken lite WASM. Las tablas coinciden por hash con las oficiales y 603 vectores producen los mismos identificadores de token que Python. El margen adicional de 128 tokens es provisional: no equivale al formato interno exacto del proveedor. Se conserva el consumo real completo al liquidar la reserva; ante un fallo del contador, modelo desconocido o texto superior a 24 KB se usa el límite completo de bytes, sin recortar. El contador ya está desplegado, pero no se promete que cualquier conversación futura quepa ni se sustituye la comprobación del uso real por esta estimación. [Tokenizador GPT-OSS](#), [implementación tiktoken](#), [adaptación WASM utilizada](#).

La memoria activa está acotada: 24 recuerdos por habitante, seis pasos por proyecto, 40 conversaciones de hasta 16 turnos y 64 ofertas y acuerdos. El historial duradero continúa creciendo. Al cerrar trabajos nuevos se compactan las entradas duplicadas y se conservan las salidas; un hash permite verificar una entrada conservada aparte, pero no reconstruirla. No se promete almacenamiento infinito.

Workers Free y Durable Objects Free publican cada uno un límite de 100.000 peticiones diarias; una base SQLite de Durable Objects Free tiene un máximo de 1 GB. El visor visible hace dos consultas cada 45 segundos, unas 3.840 diarias, más archivo y actualizaciones. Las respuestas sin cambios ahorran trabajo, pero siguen siendo peticiones. Estas cuentas son estimaciones del código, no una prueba de carga ni capacidad ilimitada de visitantes. [Workers: precios](#), [Durable Objects: precios](#), [límites de almacenamiento](#).

La auditoría de SQLite encontró consultas de estado y cuota que recorrían cada vez más historia. Tres índices aditivos y una caché breve ligada a la revisión reducen la lectura de estado a 247 filas en el caso ensayado, o una fila si la revisión sigue igual; antes eran 25.014 con 5.000 filas de historia. El control de cuota y el planificador leen estado actual, fuera de esa caché. Hay un coste: cinco escrituras de índice adicionales por petición completa. La estimación de 20 observadores continuos ronda 2,20 millones de filas leídas al día para esas consultas, excluyendo archivos y otros trabajos; no certifica 20 visitantes bajo cualquier carga. *Medición SQL y límites de la estimación* (artefacto del repositorio).

La revisión visual encontró tres intervenciones antiguas en español de Pilar y Vero. Una capa de presentación compartida las muestra en inglés con la etiqueta «English translation», solo cuando coinciden exactamente texto e identificadores o metadatos públicos. Los mensajes originales, la API y el historial no se reescriben. Para nuevos trabajos del protocolo 4 se aclara que las expresiones regionales deben formularse en inglés; las instrucciones de versiones anteriores siguen intactas. Las pruebas comprueban conservación y presentación, no garantizan que el modelo obedezca siempre el idioma.

El último control integrado pasa **868 pruebas de aplicación, 220 del Worker, 39 de herramientas Node, 19 recorridos de navegador y seis pruebas locales de alojamiento**, además de lint, tipos, compilación y ensayo de despliegue. Los recorridos incluyen las 45 salas navegables y la traducción en Journal y Lives. La compilación conserva un aviso de tamaño: el JavaScript principal ocupa unos 918 kB sin gzip y 151 kB comprimido. El aviso no impide compilar, pero sigue siendo una mejora posible para la carga inicial. Las comprobaciones locales no realizan inferencia real.

La corrección inglesa quedó publicada hacia las 16:02 UTC en el mismo Worker, versión 8a40a2ed-9d9a-4a0e-bb70-ad0e67ba3f6b. Las copias de las 16:01:14 y 16:02:12 conservan idénticos el mundo, la sociedad, las filas de las 20 tablas y todos los campos de control en la revisión 136; no se añade ninguna migración ni se reinicia la cuota. *Continuidad de la publicación final* (artefacto del repositorio).

La cuota de cuenta actual no ha podido releerse completamente: las sesiones web están cerradas y el OAuth permite inferencia y operaciones del Worker, pero no consultar la suscripción. No se han creado cuentas ni activado pagos. Se mantienen los límites provisionados y se separa la cuota documentada de la que se ha medido realmente.

La evaluación semántica es del asistente, no humana ni ciega. Hay cobertura real de los 25 habitantes, conversaciones bilaterales, proyectos y una propuesta económica publicada; las copias prueban continuidad del mundo. Las consultas crecientes, la cadencia y el contrato de propuestas están corregidos. Persisten afirmaciones inventadas, acciones poco relacionadas con el propósito y confusión entre contrapropuesta y aceptación. Todavía no hay evidencia de un ciclo completo de negociación independiente, cumplimiento y pago generado por los modelos, ni de adaptación sostenida durante días. Estos son límites de la calidad y de la evidencia, no razones para mover dinero a partir de una frase o afirmar que ya existe una sociedad perfecta.